

Tổng quan về ước lượng tương phản nhiễu

Từ Local NCE đến Global NCE và InfoNCE

Mục lục

1	Khái quát sơ lược	2
2	Nội dung chính	2
2.1	Local NCE	2
2.1.1	Bài toán gốc và điểm nghẽn của Hàm Softmax toàn cục (Full Softmax)	2
2.1.2	Chuyển đổi sang bài toán phân loại nhị phân	3
2.1.3	Cơ chế sinh dữ liệu	3
2.1.4	Tự chuẩn hóa (Self-normalization)	3
2.1.5	Chứng minh lại công thức (a) và (b) dựa trên Định lý Bayes	4
2.1.6	Hàm mục tiêu	4
2.1.7	Cơ chế điều phối lực phạt Gradient thông minh	5
2.2	Global NCE	6
2.2.1	Bài toán gốc và Động lực nâng cấp	6
2.2.2	Cơ chế sinh dữ liệu tổng thể	6
2.2.3	Chứng minh Xác suất hậu nghiệm Bayes (Conditional Distribution over Indices)	7
2.2.4	Hàm mục tiêu toán học (Objective Function)	8
2.2.5	Ưu điểm vượt trội so với Local NCE	8
2.2.6	Cơ chế tự triệt tiêu	8
2.3	InfoNCE	9
2.3.1	Hàm chấm điểm tối ưu khi $q_Y(y) = \text{pop}_Y(y)$	9
2.4	InfoNCE – Hạ chặn của Mutual Information (Thông tin tương hỗ)	10
2.4.1	Khai triển hàm Loss InfoNCE từ góc nhìn mô hình lý tưởng	10

1 Khái quát sơ lược

Khái niệm chung và Động lực bài toán: Trong nhiều bài toán học thống kê và học máy, mục tiêu của mô hình là ước lượng một phân phối xác suất từ dữ liệu quan sát hoặc một phân phối xác suất có điều kiện giữa các biến. Cách tiếp cận truyền thống thường dựa trên nguyên lý cực đại hóa hàm hợp lý (Maximum Likelihood Estimation - MLE). Tuy nhiên, đối với các mô hình có không gian đầu ra rất lớn hoặc các mô hình xác suất chưa được chuẩn hóa, việc tối ưu trực tiếp hàm hợp lý thường trở nên không khả thi do phải tính toán partition function, một phép chuẩn hóa có chi phí rất lớn.

Để giải quyết khó khăn này, Noise Contrastive Estimation (NCE) được đề xuất như một phương pháp chuyển bài toán ước lượng mật độ thành bài toán phân biệt giữa dữ liệu thực (real data) và dữ liệu nhiễu (noise data). Cụ thể thay vì tính trực tiếp partition function, NCE huấn luyện một bộ phân loại để nhận biết mẫu nào đến từ phân phối dữ liệu và mẫu nào được sinh từ một phân phối nhiễu đã biết. Các tham số của mô hình sau đó được học thông qua việc tối ưu bài toán phân loại này.

Ý tưởng của NCE đã trở thành nền tảng cho nhiều biến thể sau này, tiêu biểu là Local NCE, Global NCE và đặc biệt là InfoNCE. Các phương pháp này hiện được sử dụng rộng rãi trong học biểu diễn tương phản (Contrastive Representation Learning), các mô hình thị giác-ngôn ngữ (Vision-Language Models) cũng như nhiều bài toán học biểu diễn hiện đại. Từ cùng một nguyên lý tương phản, việc lựa chọn cách xây dựng xác suất hậu nghiệm và hàm mục tiêu tối ưu dẫn đến ba biến thể thiết kế phổ biến của NCE như sau.

1. **Local NCE (Binary NCE):** Phân loại nhị phân độc lập. Đối với mỗi mẫu quan sát, mô hình thực hiện một phép suy luận nhị phân độc lập để ước lượng xác suất hậu nghiệm rằng mẫu đó thuộc phân phối dữ liệu thay vì phân phối nhiễu. Việc xử lý từng mẫu riêng biệt giúp giảm đáng kể chi phí tính toán, nhưng đồng thời khiến phương pháp trong nhiều trường hợp dựa vào giả thiết xấp xỉ tự chuẩn hóa của mô hình.
2. **Global NCE (Ranking NCE):** Phương pháp này chuyển bài toán thành một nhiệm vụ nhận dạng đa lớp trên tập ứng viên. Mỗi tập gồm N ứng viên được xử lý như một bài toán suy luận duy nhất nhằm xác định mẫu nào được sinh ra từ phân phối dữ liệu. Cách tiếp cận toàn cục này làm cho hằng số chuẩn hóa bị khử tự nhiên trong xác suất hậu nghiệm và do đó không còn phụ thuộc vào giả thiết tự chuẩn hóa của mô hình.
3. **InfoNCE Tối đa hóa Mutual Information:** Có thể được xem như một trường hợp đặc biệt của Global NCE dưới một cấu hình lấy mẫu nhiễu cụ thể. Khi phân phối nhiễu được lựa chọn là phân phối biên của biến mục tiêu, việc tối ưu mục tiêu InfoNCE tương đương với việc cực đại hóa một hạ chặn của thông tin tương hỗ giữa các biến ngẫu nhiên liên quan. Góc nhìn này đã trở thành một trong những nền tảng lý thuyết quan trọng của học biểu diễn tự giám sát và các mô hình thị giác-ngôn ngữ hiện đại.

2 Nội dung chính

2.1 Local NCE

2.1.1 Bài toán gốc và điểm nghẽn của Hàm Softmax toàn cục (Full Softmax)

Trong các mô hình xác suất thống kê và học máy truyền thống, mục tiêu cốt lõi là ước lượng phân phối xác suất có điều kiện của một mẫu mục tiêu x (Target) dựa trên một ngữ cảnh c (Context) cho trước. Mô hình hóa mối quan hệ này thường sử dụng hàm Softmax toàn cục dưới dạng thức sau:

$$p(x | c) = \frac{f(x, c)}{\sum_{x'} f(x', c)} = \frac{f(x, c)}{Z_{\theta}(c)} \quad (1)$$

Trong đó:

- $f(\mathbf{x}, \mathbf{c})$ — Hàm chấm điểm (Scoring function) chưa chuẩn hóa, có nhiệm vụ gán một giá trị thực ($\mathbb{R}$) đại diện cho mức độ tương thích của mục tiêu x đối với bối cảnh c .
- $Z_{\theta}(c) = \sum_{x'} f(x', c)$ — Hàm phân vùng (Partition function) hoặc hằng số chuẩn hóa phụ thuộc vào ngữ cảnh c . Vai trò của nó là đưa tổng diện tích phân phối xác suất của toàn bộ không gian mẫu ứng viên x' về bằng 1.

- θ (Theta) — Vector tham số của mô hình. Quá trình huấn luyện thực chất là quá trình tìm kiếm cấu hình tham số tối ưu sao cho phân phối xác suất do mô hình sinh ra khớp tốt nhất với quy luật sinh dữ liệu quan sát.

2.1.2 Chuyển đổi sang bài toán phân loại nhị phân

Để khắc phục điểm nghẽn tính toán của hằng số chuẩn hóa $Z_\theta(c)$ (vốn đòi hỏi phải quét qua và tính tổng trên toàn bộ không gian mẫu ứng viên), Local NCE không trực tiếp cực đại hóa hàm hợp lý của phân phối xác suất đã chuẩn hóa. Thay vào đó, phương pháp này thay thế hoàn toàn bài toán ước lượng phân phối đa lớp phức tạp bằng một chuỗi các bài toán phân loại nhị phân độc lập (Independent Binary Classification).

Thay vì bắt mô hình phải cạnh tranh xác suất để chọn ra một đáp án đúng duy nhất giữa hàng triệu ứng viên khả thi, Local NCE chia tách tập dữ liệu đầu vào thành hai nguồn riêng biệt: Dữ liệu thật và Dữ liệu nhiễu. Nhiệm vụ của mô hình lúc này được quy giản về một mục tiêu đơn giản hơn nhiều: đối với mỗi mẫu mục tiêu x đặt trong một ngữ cảnh c cụ thể, mô hình chỉ cần quyết định xem cặp dữ liệu đó được sinh ra từ phân phối thực ($D = 1$) hay từ một phân phối nhiễu đã biết trước ($D = 0$).

2.1.3 Cơ chế sinh dữ liệu

Cơ chế lấy dữ liệu tổng thể gồm 2 nguồn độc lập cung cấp mẫu cho mô hình:

- Ta lấy đúng một mẫu dữ liệu thật từ phân phối dữ liệu thực $p_{\text{data}}(x | c)$, tương ứng với $D=1$.
- Ta lấy k mẫu dữ liệu nhiễu ngẫu nhiên từ phân phối nhiễu $q(x)$, ($D = 0$).

Từ tỷ lệ mẫu này (1 thật và k nhiễu), áp dụng công thức xác suất Bayes để tính xác suất một mẫu quan sát được (x, c) là nhiễu hay thật:

- Xác suất mẫu đó là nhiễu: $\mathbf{P}(D = 0 | \mathbf{x}, c) = \frac{\mathbf{k} \cdot \mathbf{q}(\mathbf{x})}{\mathbf{p}_{\text{data}}(\mathbf{x} | c) + \mathbf{k} \cdot \mathbf{q}(\mathbf{x})}$
- Xác suất mẫu đó là thật: $\mathbf{P}(D = 1 | \mathbf{x}, c) = \frac{\mathbf{p}_{\text{data}}(\mathbf{x} | c)}{\mathbf{p}_{\text{data}}(\mathbf{x} | c) + \mathbf{k} \cdot \mathbf{q}(\mathbf{x})}$

Nhận xét trực giác: Mẫu nào có mật độ xác suất thực $p_{\text{data}}(x | c)$ càng cao so với phân phối nhiễu $q(x)$ thì mô hình càng có khả năng cao dự đoán đó là dữ liệu thật ($D = 1$).

2.1.4 Tự chuẩn hóa (Self-normalization)

Trong NCE gốc, phân phối mô hình được biểu diễn dưới dạng:

$$p_\theta(x | c) = \frac{f_\theta(x, c)}{Z_\theta(c)} \quad (2)$$

Một đặc điểm quan trọng của NCE gốc là nó coi hằng số chuẩn hóa $Z_\theta(c)$ là có thể được học như một tham số bổ sung thay vì phải tính chính xác bằng cách quét toàn bộ không gian mẫu.

Tuy nhiên trong nhiều triển khai thực tế, người ta thường áp dụng tự chuẩn hóa (self-normalization) hoặc trực tiếp đặt: $Z_\theta(c) \approx 1$ nhằm đơn giản hóa việc tính toán.

Từ đó dẫn tới hệ quả: $\mathbf{p}_\theta(\mathbf{x} | c) \approx \mathbf{f}_\theta(\mathbf{x}, c)$.

Với điều này, ta có thể viết lại các công thức xác suất có điều kiện:

- $\mathbf{P}(D = 0 | \mathbf{x}, c) = \frac{\mathbf{k} \cdot \mathbf{q}(\mathbf{x})}{\mathbf{f}_\theta(\mathbf{x}, c) + \mathbf{k} \cdot \mathbf{q}(\mathbf{x})}$
- $\mathbf{P}(D = 1 | \mathbf{x}, c) = \frac{\mathbf{f}_\theta(\mathbf{x}, c)}{\mathbf{f}_\theta(\mathbf{x}, c) + \mathbf{k} \cdot \mathbf{q}(\mathbf{x})}$

2.1.5 Chứng minh lại công thức (a) và (b) dựa trên Định lý Bayes

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)} \quad (3)$$

Theo cơ chế sinh dữ liệu hỗn hợp, tổng số mẫu mà mô hình nhận được trong một lượt xử lý là $(k + 1)$ mẫu (bao gồm đúng 1 mẫu dữ liệu thật và k mẫu dữ liệu nhiễu). Do đó, xác suất tiên nghiệm để một mẫu chọn ngẫu nhiên rơi vào nhóm thật ($D = 1$) hoặc nhóm nhiễu ($D = 0$) lần lượt là:

$$P(D = 1) = \frac{1}{k + 1} \quad P(D = 0) = \frac{k}{k + 1} \quad (4)$$

Mật độ xác suất điều kiện để rút được một phần tử mục tiêu x cụ thể từ bối cảnh c đối với từng nguồn dữ liệu được định nghĩa như sau:

$$p(\mathbf{x} | D = 1, \mathbf{c}) = \mathbf{p}_{\text{data}}(\mathbf{x} | \mathbf{c}) \quad p(\mathbf{x} | D = 0, \mathbf{c}) = \mathbf{q}(\mathbf{x}) \quad (5)$$

Khi mô hình nhận một mẫu x trong ngữ cảnh c , xác suất hậu nghiệm để mẫu x đó thực sự là dữ liệu thật ($D = 1$) được tính như sau:

$$P(D = 1 | x, c) = \frac{p(x | D = 1, c) \cdot P(D = 1)}{p(x | c)} \quad (*) \quad (6)$$

Khai triển thành phần mẫu số (Xác suất toàn phần):

$$p(x | c) = p(x | D = 1, c) \cdot P(D = 1) + p(x | D = 0, c) \cdot P(D = 0) \quad (7)$$

$$= p_{\text{data}}(x | c) \cdot \frac{1}{k + 1} + q(x) \cdot \frac{k}{k + 1} = \frac{p_{\text{data}}(x | c) + k \cdot q(x)}{1 + k} \quad (8)$$

Thế giá trị mẫu số và tử số vừa khai triển ngược lại vào phương trình Bayes (6), ta thu được:

$$P(D = 1 | \mathbf{x}, \mathbf{c}) = \frac{\mathbf{p}_{\text{data}}(\mathbf{x} | \mathbf{c})}{\mathbf{p}_{\text{data}}(\mathbf{x} | \mathbf{c}) + \mathbf{k} \cdot \mathbf{q}(\mathbf{x})} \quad (9)$$

$$P(D = 0 | \mathbf{x}, \mathbf{c}) = 1 - P(D = 1 | \mathbf{x}, \mathbf{c}) = \frac{\mathbf{k} \cdot \mathbf{q}(\mathbf{x})}{\mathbf{p}_{\text{data}}(\mathbf{x} | \mathbf{c}) + \mathbf{k} \cdot \mathbf{q}(\mathbf{x})} \quad (10)$$

Do self-normalization $Z_{\theta}(c) \approx 1$, ta có $p_{\theta}(x | c) \approx f_{\theta}(x, c)$. Thay vào kết quả Bayes vừa chứng minh, ta thu được công thức (a) và (b) đã nêu ở trên.

2.1.6 Hàm mục tiêu

Hàm mục tiêu (Maximum Likelihood): Mục tiêu là tối đa hóa hàm log-likelihood, đồng nghĩa với việc tối đa hóa xác suất nhận diện đúng mẫu thật và mẫu nhiễu:

- Tối đa hóa mẫu thật: $\log P(D = 1 | x, c)$
- Tối đa hóa k mẫu nhiễu: $\log P(D = 0 | x'_i, c)$

Công thức hàm mục tiêu tổng quát cần tối đa hóa:

$$\log P(D = 1 | x, c) + \sum_{i=1}^k \log P(D = 0 | x'_i, c) \quad \text{với } x'_i \sim q \quad (11)$$

Biến đổi thành phần tổng của mẫu nhiễu:

$$\sum_{i=1}^k \log P(D = 0 | x'_i, c) = k \cdot \left[\frac{1}{k} \sum_{i=1}^k \log P(D = 0 | x'_i, c) \right] \quad (12)$$

Biểu thức trong ngoặc vuông chính là giá trị trung bình cộng của hàm $\log P(D = 0)$. Theo Luật số lớn, khi lấy số lượng mẫu nghiệm nhiễu đủ lớn, giá trị trung bình này sẽ hội tụ về giá trị Kỳ vọng toán học lý thuyết của phân phối đó:

$$(12) \rightarrow k \cdot \mathbb{E}_{x' \sim q} [\log P(D = 0 \mid x', c)] \quad (13)$$

Từ đó, hàm mục tiêu đầy đủ nhằm tối đa hóa lượng Log-Likelihood của Local NCE được định nghĩa:

$$\mathbf{J}_{\text{localNCE}} = \sum_{(x,c) \in \mathcal{D}} [\log P(D = 1 \mid x, c) + k \cdot \mathbb{E}_{x' \sim q} (\log P(D = 0 \mid x', c))] \quad (14)$$

Trong đó:

- $(\mathbf{x}, \mathbf{c}) \in \mathcal{D}$: Cặp dữ liệu thực tế lấy từ tập huấn luyện.
- $\mathbf{x}' \sim \mathbf{q}$: Mẫu nhiễu sinh ra từ phân phối nhiễu biết trước $q(x)$.
- k : Số lượng mẫu nhiễu được cấu hình.

Do phép toán tính kỳ vọng chính xác yêu cầu phải quét qua toàn bộ mọi từ khả thi (*nhưng sẽ là quay về vấn đề ban đầu của bài toán chi phí tính toán*), ta áp dụng công thức **Xấp xỉ Monte-Carlo**, Kỳ vọng được xấp xỉ bằng trung bình trên k mẫu nhiễu được lấy ngẫu nhiên từ $q(x)$.

$$\mathbf{J}_{\text{localNCE, MC}} = \sum_{(x,c) \in \mathcal{D}} \left(\log P(D = 1 \mid x, c) + \sum_{\substack{i=1 \\ x' \sim q}}^k \log P(D = 0 \mid x'_i, c) \right) \quad (15)$$

2.1.7 Cơ chế điều phối lực phạt Gradient thông minh

Khi mô hình nhận vào 1 từ thật x trong ngữ cảnh c và ta sinh ra k từ nhiễu x_i , công thức đạo hàm (lực Gradient) để cập nhật cho tham số θ được triển khai tổng quát như sau:

$$\begin{aligned} \frac{\partial \mathbf{J}_{\mathbf{c}, \mathbf{x}}(\theta)}{\partial \theta} &= \left\{ \frac{k \cdot p_n(x)}{p_\theta^h(x) + k \cdot p_n(x)} \right\} \cdot \frac{\partial \log p_\theta^h(x)}{\partial \theta} \\ &\quad - \sum_{i=1}^k \left\{ \frac{p_\theta^h(x_i)}{p_\theta^h(x_i) + k \cdot p_n(x_i)} \right\} \cdot \frac{\partial \log p_\theta^h(x_i)}{\partial \theta} \end{aligned} \quad (16)$$

Phân giải công thức:

- θ (**Theta**): Tập hợp các tham số của mô hình cần được cập nhật và tối ưu hóa.
- $\mathbf{c}$ (**Context**): Ngữ cảnh đầu vào cho trước (ví dụ: các từ phía trước trong câu, hoặc một đoạn văn bản prompt).
- $\mathbf{x}$ (**Word**): Từ mục tiêu thật sự (Positive sample / Dữ liệu thật) xuất hiện trong ngữ cảnh h từ tập huấn luyện.
- $\mathbf{x}_i$: Mẫu nhiễu thứ i được lấy từ phân phối nhiễu $q(x)$.
- k : Số lượng mẫu nhiễu được cấu hình để đối trọng với 1 mẫu thật.
- $\mathbf{J}_{\mathbf{h}, \mathbf{w}}(\theta)$: Hàm mục tiêu cục bộ của Local NCE xét trên một lượt lấy mẫu dữ liệu cụ thể.
- $\frac{\partial \mathbf{J}_{\mathbf{h}, \mathbf{w}}(\theta)}{\partial \theta}$: Đạo hàm riêng (Gradient) của hàm mục tiêu theo tham số θ . Đây chính là “lực” quyết định các trọng số của mô hình AI sẽ thay đổi như thế nào và theo hướng nào.
- $\mathbf{p}_\theta^h(\mathbf{x})$: Xác suất mô hình gán cho từ x trong ngữ cảnh c .
- $\mathbf{p}_n(\mathbf{x})$ và $\mathbf{p}_n(\mathbf{x}_i)$: Xác suất của từ x và từ nhiễu x_i dựa trên phân phối nhiễu biết trước (Noise distribution).
- $\left[\frac{\partial \log p_\theta^h(x)}{\partial \theta} \right]$: Gradient cơ bản phản ánh mức độ thay đổi của log xác suất dữ liệu thật theo tham số mô hình.

- $\left[\frac{\partial \log p_{\theta}^h(x_i)}{\partial \theta} \right]$: Gradient cơ bản phản ánh mức độ mô hình đang gán xác suất cho mẫu nhiễu.

Hai phân số đứng trước các gradient cơ bản đóng vai trò là hệ số điều phối (adaptive weighting coefficients), tự động điều chỉnh cường độ cập nhật dựa trên mức độ mô hình đang phân biệt đúng hay sai giữa dữ liệu thật và dữ liệu nhiễu.

Phân tích chuyên sâu về hai cơ chế lực điều phối trong quá trình cập nhật trọng số :

A. Hệ số khuếch đại gradient positive (Áp dụng lúc gặp dữ liệu thật):

$$\text{Hệ số khuếch đại gradient positive} = \frac{k \cdot p_n(x)}{p_{\theta}^h(x) + k \cdot p_n(x)} \quad (17)$$

Nếu mô hình hiện tại chấm điểm rất thấp cho từ thật x (tức là đại lượng $p_{\theta}^h(x)$ rất nhỏ) $p_{\theta}(w | h) \ll k \cdot p_n(x)$, hệ số lập tức tiến mạnh về giá trị tối đa là 1. Đại lượng này đóng vai trò đo lường mức độ “ngốc nghếch” hoặc thiếu sót của mô hình khi bỏ lỡ mất từ đúng x trong ngữ cảnh c . Ngược lại, nếu mô hình đã đánh giá rất cao từ đúng $p_{\theta}(x | c) \gg k \cdot p_n(x)$, hệ số tiến gần về 0. Thành phần gradient positive chỉ được tính từ một mẫu dữ liệu thật duy nhất x , thay vì phải tính trên toàn bộ từ vựng.

B. Hệ số khuếch đại gradient negative (Áp dụng khi xử lý tập dữ liệu nhiễu/giả):

$$\text{Hệ số khuếch đại gradient negative} = \frac{p_{\theta}^h(x_i)}{p_{\theta}^h(x_i) + k \cdot p_n(x_i)} \quad (18)$$

Hệ số này quyết định mức độ mô hình cần bị điều chỉnh đối với từng mẫu nhiễu. Hệ số này được tính toán bằng cách quét qua k từ giả/nhiều. Nó đo lường mức độ mô hình bị “ảo tưởng” (hallucination), lầm tưởng một từ giả x_i là dữ liệu thật. Nếu điểm số ảo tưởng càng cao $p_{\theta}(x_i | c) \gg k \cdot p_n(x_i)$ thì hệ số ngay lập tức tiến về 1, Gradient phạt được giữ gần như nguyên vẹn, tạo ra áp lực mạnh để kéo xác suất của mẫu nhiễu xuống. Ngược lại, nếu mẫu nhiễu đã được mô hình nhận diện chính xác, $p_{\theta}(x_i | c) \ll k \cdot p_n(x_i)$, hệ số tiến về 0, Mẫu nhiễu đó gần như không còn đóng góp gradient.

Nhờ vậy mô hình tự động tập trung tài nguyên học tập vào các mẫu nhiễu khó phân biệt nhất.

Kết luận: Hai hệ số điều phối này tạo nên cơ chế cập nhật thích nghi (adaptive gradient weighting). Những mẫu mà mô hình đang dự đoán sai sẽ tạo ra gradient mạnh, trong khi những mẫu đã được xử lý tốt sẽ tự động giảm ảnh hưởng. Nhờ đó Local NCE tập trung năng lực học vào các trường hợp khó phân biệt mà không cần tính toán hàm phân vùng toàn cục Z .

Ghi chú biên soạn về quy ước ký hiệu:

Do tập tài liệu này được tổng hợp và đối chiếu từ nhiều nguồn nghiên cứu độc lập khác nhau trong văn liệu học máy (dẫn đến những sai khác tự nhiên trong cách biểu diễn các đại lượng ở mỗi tài liệu gốc), hệ thống ký hiệu trong chương này sẽ có sự dịch chuyển vai trò nhằm bảo toàn cấu trúc ma trận phân phối nguyên bản.

Sự thay đổi hình thức này hoàn toàn xuất phát từ việc tôn trọng định dạng của các nguồn tài liệu gốc, bản chất logic toán học thống kê giữa hai chương vẫn giữ nguyên tính liên kết nhất quán.

2.2 Global NCE

2.2.1 Bài toán gốc và Động lực nâng cấp

Nếu như Local NCE quy giản bài toán về chuỗi các quyết định nhị phân độc lập (Phán xét từng mẫu riêng lẻ là Thật hay Giả), thì Global NCE nâng cấp tư duy này lên diện Xếp hạng đa lớp (Ranking / Multiple Choice).

Trong thực tế huấn luyện, thay vì bắt mô hình phải tối ưu hóa ranh giới phân loại tuyệt đối cho từng từ đơn lẻ, Global NCE đặt mô hình vào một bối cảnh mang tính so sánh toàn cục. Nhìn vào tập hợp chứa duy nhất 1 mẫu dữ liệu thật và $N - 1$ mẫu dữ liệu nhiễu để chỉ ra chính xác ứng viên nào là câu trả lời đúng.

2.2.2 Cơ chế sinh dữ liệu tổng thể

Hệ thống lấy mẫu của Global NCE thiết lập một phân phối xác suất hợp trên không gian của chỉ mục vị trí, mẫu thực và tập hợp mẫu nhiễu.

1. Đầu tiên, ta rút ngẫu nhiên 1 chỉ mục $i \in \{1 \dots N\}$ theo phân phối đều với xác suất $P(i) = 1/N$, nghĩa là mọi vị trí từ 1 đến N đều có cơ hội được chọn ngang nhau.
2. Tại vị trí chỉ mục i đã chọn, ta tiến hành lập mẫu một cặp dữ liệu thật từ phân phối thực tế của dữ liệu gốc $(x, y_i) \sim \text{pop}_{XY}$. Cặp dữ liệu này gồm điểm neo ngữ cảnh x (Context) và mục tiêu thực tế y_i (Target).
3. Tại tất cả các chỉ mục vị trí còn lại ($j \neq i$), ta độc lập rút các mẫu giả từ phân phối nhiễu cấu hình trước: $y_j \sim q_Y$. Các mẫu giả y_j này được rút một cách hoàn toàn **độc lập** với nhau.

Toàn bộ quy trình phối hợp 3 bước trên được cô đọng bằng công thức toán học về hàm mật độ phân phối xác suất hợp:

$$\text{pop}_{I|XY^N}^{q_Y}(i, x, y_1 \dots y_N) := \frac{1}{N} \text{pop}_{XY}(x, y_i) \prod_{j \neq i} q_Y(y_j) \quad (19)$$

Giải mã chi tiết hệ thống ký hiệu:

- $\text{pop}_{I|XY^N}^{q_Y}$: Đại diện cho hàm mật độ xác suất hợp của toàn bộ hệ thống dữ liệu đầu vào.
 - Ký hiệu dưới chân $I|XY^N$ chỉ ra các thành phần tham gia vào không gian hợp này, bao gồm: chỉ mục i , ngữ cảnh x , và chuỗi N biến mục tiêu $Y^N = (y_1, \dots, y_N)$.
 - Ký hiệu trên đầu q_Y để nhắc nhở rằng phân phối hỗn hợp này có sự đóng góp tham gia của nguồn nhiễu q_Y .
- $\frac{1}{N}$: Xác suất tiên nghiệm phân phối đều khi chọn vị trí i cho mẫu thật (kết quả từ Bước 1).
- $\text{pop}_{XY}(x, y_i)$: Hàm mật độ xác suất xuất hiện của cặp dữ liệu thật (x, y_i) tại vị trí i . Đại lượng này có thể viết tường minh dưới dạng tích: $\text{pop}_X(x) \cdot \text{pop}_{Y|X}(y_i|x)$.
- **Toán tử tích $\prod_{j \neq i} q_Y(y_j)$** : Thể hiện xác suất đồng thời khi lấp đầy $N - 1$ vị trí trống còn lại bằng các mẫu nhiễu được rút một cách độc lập thống kê từ phân phối q_Y (kết quả từ Bước 3).

2.2.3 Chứng minh Xác suất hậu nghiệm Bayes (Conditional Distribution over Indices)

Khi mô hình được cung cấp toàn bộ tập hợp N ứng viên cùng với điểm neo ngữ cảnh x , xác suất hậu nghiệm lý thuyết để chỉ mục vị trí i thực sự chứa mẫu dữ liệu thật được khai triển trực tiếp qua Định lý Bayes:

$$\text{pop}_{I|XY^N}^{q_Y}(i | x, y_1 \dots y_N) = \frac{\text{pop}_{Y|X}(y_i | x) \prod_{j \neq i} q_Y(y_j)}{\sum_{k=1}^N \text{pop}_{Y|X}(y_k | x) \prod_{j \neq k} q_Y(y_j)} = \frac{\frac{\text{pop}_{Y|X}(y_i | x)}{q_Y(y_i)}}{\sum_{k=1}^N \frac{\text{pop}_{Y|X}(y_k | x)}{q_Y(y_k)}} \quad (20)$$

Giải mã chi tiết hệ thống ký hiệu công thức (20):

- $\text{pop}_{I|XY^N}^{q_Y}(i | x, y_1 \dots y_N)$: Xác suất hậu nghiệm (*Posterior probability*) lý thuyết để mẫu dữ liệu thật nằm chính xác ở vị trí chỉ mục i , sau khi mô hình đã quan sát thấy toàn bộ cấu hình đầu vào gồm điểm neo ngữ cảnh x và danh sách N ứng viên $(y_1 \dots y_N)$.
- $\frac{1}{N} \text{pop}_{Y|X}(y_i | x) \prod_{j \neq i} q_Y(y_j)$ (**Tỷ số trung gian**): Mật độ xác suất hợp của kịch bản lý tưởng: vị trí i chứa mẫu thật sinh ra từ phân phối thực điều kiện $\text{pop}_{Y|X}$, còn $N - 1$ vị trí còn lại ($j \neq i$) là mẫu giả từ phân phối nhiễu q_Y .
- $\sum_{k=1}^N \frac{1}{N} \text{pop}_{Y|X}(y_k | x) \prod_{j \neq k} q_Y(y_j)$ (**Mẫu số trung gian**): Hàm mật độ xác suất toàn phần, đóng vai trò là hằng số chuẩn hóa thu được bằng cách quét qua tất cả các kịch bản vị trí k khả thi mà mẫu thật có thể xuất hiện.
- $\frac{\text{pop}_{Y|X}(y_i | x)}{q_Y(y_i)}$: Tỷ lệ mật độ (*Density ratio*) phản ánh mức độ vượt trội của riêng mẫu ứng viên y_i khi đặt dưới phân phối thực so với phân phối nhiễu nền.

Cơ chế triệt tiêu nhiễu toán học: Để đạt được dạng thu gọn cuối cùng ở vế phải, cả tử số và mẫu số đã được chia đồng thời cho lượng tích toàn phần $\prod_{m=1}^N q_Y(y_m)$. Phép biến đổi đại số này triệt tiêu hoàn toàn sự ràng buộc đan xen của các mẫu nhiễu vị trí khác, đưa bài toán ước lượng đa lớp phức tạp về một cấu trúc hàm Softmax chuẩn mực tính trên tỷ số mật độ đơn lẻ của từng ứng viên.

2.2.4 Hàm mục tiêu toán học (Objective Function)

Để ước lượng xác suất hậu nghiệm Bayes nêu trên, Global NCE sử dụng hàm chấm điểm chưa chuẩn hóa $s^\theta(x, y)$ của mô hình thông qua toán tử Softmax trên không gian tập mẫu ứng viên:

$$p_{I|XY^N}^\theta(i | x, y_1 \dots y_N) := \frac{\exp(s^\theta(x, y_i))}{\sum_{j=1}^N \exp(s^\theta(x, y_j))} \quad \forall i \in \{1 \dots N\} \quad (21)$$

Mô hình được huấn luyện bằng cách tối thiểu hóa **hàm mất mát** Cross-Entropy (tương đương tối đa hóa lượng Log-Likelihood xếp hạng đúng) giữa phân phối thực tế của dữ liệu và dự đoán của mô hình:

$$\mathcal{L}_{\text{GlobalNCE}}(\theta) = \mathbb{E}_{(i, x, y_1 \dots y_N) \sim \text{pop}_{I, XY^N}^{q_Y}} \left[-\log \frac{\exp(s^\theta(x, y_i))}{\sum_{j=1}^N \exp(s^\theta(x, y_j))} \right] \quad (22)$$

2.2.5 Ưu điểm vượt trội so với Local NCE

Ưu điểm vượt trội so với Local NCE: Dựa trên đặc tính toán học nội tại của hàm mục tiêu Cross-Entropy, điểm cực tiểu toàn cục (Global Minimum) được chứng minh là sẽ đạt được khi và chỉ khi phân phối xác suất do mô hình dự đoán trùng khít hoàn toàn với phân phối thực tế của dữ liệu.

Tại trạng thái tối ưu tuyệt đối này, hàm chấm điểm $s^\theta(x, y)$ do mô hình học được sẽ tự động khôi phục lại chuẩn xác bản chất tỷ lệ của phân phối có điều kiện dựa trên công thức toán học sau (tham khảo thêm tại: *Noise Contrastive Estimation* của Karl Stratos):

$$s^{\theta^{q_Y}}(x, y) = \log \frac{\text{pop}_{Y|X}(y | x)}{q_Y(y)} + \log C_x \quad \forall x \in \mathcal{X}, y \in \mathcal{Y} \quad (\text{BT1})$$

Điểm mấu chốt là toán tử chia của hàm Softmax đã triệt tiêu hoàn toàn sự phụ thuộc vào **hằng số phân vùng phụ thuộc ngữ cảnh** $Z(x)$. Do đó, Global NCE **không cần** áp đặt tự chuẩn hóa khắt khe $Z(c) \approx 1$ lên từng mẫu độc lập như Local NCE.

2.2.6 Cơ chế tự triệt tiêu

Xét hàm Softmax tổng quát:

$$p(i) = \frac{\exp(\text{logits}_i)}{\sum_{j=1}^N \exp(\text{logits}_j)} \quad (23)$$

Khi cộng thêm một hằng số k vào tất cả các logits:

$$p(i) = \frac{\exp(\text{logits}_i + k)}{\sum_{j=1}^N \exp(\text{logits}_j + k)} = \frac{\exp(\text{logits}_i) \cdot \exp(k)}{\exp(k) \cdot \sum_{j=1}^N \exp(\text{logits}_j)} \quad (24)$$

$$= \frac{\exp(\text{logits}_i)}{\sum_{j=1}^N \exp(\text{logits}_j)} \quad (25)$$

Mục tiêu tối thượng của mô hình là học được phân phối xác suất có điều kiện thực tế của dữ liệu $\text{pop}_{Y|X}(y | x)$, phân phối này vốn bị kìm hãm bởi hằng số phân vùng $Z(x)$ rất khó tính toán:

$$\text{pop}_{Y|X}(y | x) = \frac{\exp(S^{\text{true}}(x, y))}{Z(x)} \quad (\text{BT2})$$

Thế biểu thức (BT2) vào biểu thức (BT1):

$$S^\theta(x, y) = \log\left(\frac{\exp(S^{\text{true}}(x, y))}{Z(x) \cdot q_Y(y)}\right) + \log C_x \quad (26)$$

$$S^\theta(x, y) = S^{\text{true}}(x, y) - \log q_Y(y) + [\log C_x - \log Z(x)] \quad (27)$$

Trong đó bản chất của từng thành phần được định nghĩa như sau:

- $S^{\text{true}}(x, y)$: Điểm số tương thích gốc của dữ liệu thực.
- $[\log C_x - \log Z(x)]$: Hằng số tính. Cụm này chỉ phụ thuộc duy nhất vào ngữ cảnh đầu vào (Context x).

Cơ chế triệt tiêu hằng số cộng trong kiến trúc ma trận. Bối cảnh tính toán: Khi thực hiện phép toán Softmax của hàm Cross-Entropy theo từng hàng (row-wise) trên ma trận Logits, mô hình sẽ tính toán phân phối xác suất độc lập cho mỗi dòng.

Hệ quả hình học ma trận: Cụm hằng số bên phải $[\log C_x - \log Z(x)]$ hoàn toàn không chứa biến y . Do đó, đối với một ngữ cảnh x cố định (tương ứng với một hàng trên ma trận Logits), cụm này đóng vai trò là một hằng số cộng đều vào tất cả các ô trên hàng đó.

Ý nghĩa: Nhờ cơ chế triệt tiêu tự nhiên này, phần còn lại của biểu thức ảnh hưởng trực tiếp đến chiến lược lấy mẫu và cập nhật tham số của mô hình AI chỉ còn là:

$$S^\theta(x, y) \equiv S^{\text{true}}(x, y) - \log q_Y(y) \quad (28)$$

2.3 InfoNCE

Trong cấu hình tổng quát của Global NCE, hệ thống đặt mô hình vào một bài toán trắc nghiệm chọn đáp án đúng: Nhìn vào một tập hợp gồm N mẫu ứng viên (chứa 1 mẫu dữ liệu thực y_i và $N - 1$ mẫu giả y_j) để chỉ ra chính xác chỉ mục vị trí nào chứa câu trả lời đúng. Lúc này, phân phối nhiễu $q_Y(y)$ đóng vai trò là một biến thiết kế tự do do kỹ sư cấu hình (như phân phối đều Uniform hoặc phân phối đơn từ Unigram). InfoNCE là trường hợp đặc biệt của Global NCE.

Bản chất của hàm mục tiêu InfoNCE là tối đa hóa một chặn dưới tham số hóa cho thông tin tương hỗ $I(X, Y)$ giữa hai biến dữ liệu. Khi chúng ta lựa chọn phân phối nhiễu trùng khớp hoàn toàn với phân phối biên (Marginal Distribution) của quần thể dữ liệu thực:

$$q_Y(y) \equiv \text{pop}_Y(y) \quad (29)$$

Lúc này, InfoNCE ép mô hình phải phân biệt cặp dữ liệu có tính liên kết tương thích $(x, y) \sim \text{pop}_{XY}$ với các mẫu y được rút ngẫu nhiên hoàn toàn từ cấu trúc nền của dữ liệu thật. Sự kết hợp cấu hình phân phối nhiễu đặc biệt này dẫn đến một hệ quả lý thuyết thông tin cực kỳ sâu sắc: Hàm chấm điểm tối ưu $s^\theta(x, y)$ của mô hình sẽ phản ánh trực tiếp giá trị Thông tin tương hỗ điểm (Pointwise Mutual Information – PMI) của cặp dữ liệu.

2.3.1 Hàm chấm điểm tối ưu khi $q_Y(y) = \text{pop}_Y(y)$

Nhìn về Biểu thức (BT1). Khi ta thế điều kiện đặc biệt $q_Y(y) = \text{pop}_Y(y)$ vào phương trình trên, hàm chấm điểm tối ưu chuyển dịch thành:

$$s^{\theta^*}(x, y) = \log\left[\frac{\text{pop}_{Y|X}(y | x)}{\text{pop}_Y(y)}\right] + \log C_x \quad (30)$$

Áp dụng quy tắc xác suất điều kiện:

$$\text{pop}_{Y|X}(y | x) = \frac{\text{pop}_{XY}(x, y)}{\text{pop}_X(x)} \quad (31)$$

Thế ngược lại vào phương trình điểm số:

$$s^{\theta^*}(x, y) = \log \left[\frac{\text{pop}_{XY}(x, y)}{\text{pop}_X(x) \cdot \text{pop}_Y(y)} \right] + \log C_x \quad (32)$$

Nhận thấy biểu thức logarit bên trong:

$$\text{PMI}(x, y) = \log \left[\frac{\text{pop}_{XY}(x, y)}{\text{pop}_X(x) \cdot \text{pop}_Y(y)} \right] \quad (33)$$

chính là Pointwise Mutual Information (PMI) – Thông tin tương hỗ điểm giữa ngữ cảnh x và mục tiêu y . Do đó, ta có thể viết gọn lại mối liên hệ tối ưu:

Tại điểm hội tụ lý tưởng, hàm chấm điểm tối ưu $s^{\theta^*}(x, y)$ xấp xỉ PMI(x, y) cộng một hằng số chỉ phụ thuộc vào ngữ cảnh x – hằng số này tự triệt tiêu trong phép tính Softmax và không ảnh hưởng đến thứ tự xếp hạng. Điều đó có nghĩa là mô hình học cách phản ánh mức độ phụ thuộc thống kê giữa x và y , theo hai trường hợp cực biên:

- **Nếu x và y độc lập thống kê** ($p(x, y) = p(x) \cdot p(y)$): Khi đó, $\text{PMI}(x, y) = \log(1) = 0$. Hàm chấm điểm tối ưu sẽ gán giá trị bằng nhau cho mọi ứng viên y (sau khi cộng $\log C_x$). Phân phối xác suất đầu ra sau Softmax trở thành phân phối đều (Uniform Distribution), nghĩa là không một ứng viên nào được mô hình ưu tiên hơn ứng viên nào.
- **Nếu x và y có tương quan thuận/tương quan dương** ($p(x, y) > p(x) \cdot p(y)$): Khi đó, $\text{PMI}(x, y) > 0$. Mô hình sẽ gán điểm số $s^{\theta^*}(x, y)$ cao hơn hẳn cho ứng viên này, phản ánh việc tần suất đồng xuất hiện thực tế của cặp (x, y) vượt trội hơn hẳn so với kỳ vọng ngẫu nhiên.
- **Nếu x và y có tương quan nghịch/tương quan âm** ($p(x, y) < p(x) \cdot p(y)$): Khi đó, $\text{PMI}(x, y) < 0$. Mô hình sẽ chủ động hạ điểm số $s^{\theta^*}(x, y)$ xuống thấp, phản ánh việc cặp (x, y) này rất hiếm khi hoặc gần như không bao giờ đi cùng nhau trong thực tế (xác suất đồng xuất hiện thấp hơn cả mức ngẫu nhiên).

2.4 InfoNCE – Hạ chặn của Mutual Information (Thông tin tương hỗ)

2.4.1 Khai triển hàm Loss InfoNCE từ góc nhìn mô hình lý tưởng

Khi mô hình đạt điểm hội tụ lý tưởng với cấu hình phân phối nhiễu trùng khít với phân phối biên ($q_Y(y) \equiv \text{pop}_Y(y)$), hàm chấm điểm tối ưu đã được chứng minh ở phần trước là:

$$s^{\theta^*}(x, y) = \log \frac{p(y | x)}{p(y)} \quad (34)$$

(nhìn về Biểu thức (BT1) khi $q_Y = \text{pop}_Y$ và bỏ qua hằng số $\log C_x$ do tự triệt tiêu trong Softmax).

Bước 1: Thế hàm chấm điểm lý tưởng vào công thức Softmax. Thế hàm chấm điểm lý tưởng này vào công thức Softmax xác suất hậu nghiệm của mẫu thật (nằm ở vị trí i):

$$p_{\theta}^*(i | x, y_1, \dots, y_N) = \frac{\exp(s^{\theta^*}(x, y_i))}{\sum_{j=1}^N \exp(s^{\theta^*}(x, y_j))} = \frac{\frac{p(y_i | x)}{p(y_i)}}{\sum_{j=1}^N \frac{p(y_j | x)}{p(y_j)}} \quad (35)$$

Bước 2: Lấy logarit hai vế. Lấy logarit hai vế của xác suất dự đoán đúng này, ta có:

$$\log p_{\theta}^*(i | x, y_1, \dots, y_N) = \log \frac{p(y_i | x)}{p(y_i)} - \log \sum_{j=1}^N \frac{p(y_j | x)}{p(y_j)} \quad (36)$$

Bước 3: Lấy kỳ vọng toán học trên toàn bộ phân phối sinh dữ liệu. Để tính toán giá trị trung bình toàn cục, ta lấy kỳ vọng toán học ($\mathbb{E}$) của biểu thức trên dựa theo quy trình sinh dữ liệu của Global NCE (gồm 1 cặp thật $(x, y_i) \sim p(x, y)$ và $N - 1$ mẫu giả $y_{j \neq i} \sim p(y)$):

$$\mathbb{E}[\log p_{\theta}^*(i | \dots)] = \underbrace{\mathbb{E}_{p(x, y_i)} \left[\log \frac{p(y_i | x)}{p(y_i)} \right]}_{\text{Thành phần A}} - \underbrace{\mathbb{E} \left[\log \sum_{j=1}^N \frac{p(y_j | x)}{p(y_j)} \right]}_{\text{Thành phần B}} \quad (37)$$

Xử lý Thành phần A:

$$\text{Thành phần A} = \mathbb{E}_{p(x, y)} \left[\log \frac{p(x, y)}{p(x)p(y)} \right] = I(X; Y) \quad (38)$$

Đây chính là định nghĩa của **Thông tin tương hỗ (Mutual Information)** $I(X; Y)$.

Xử lý Thành phần B (Áp dụng bất đẳng thức Jensen): Thành phần này chứa hàm log của một phép tổng, rất khó tính toán trực tiếp. Vì hàm $-\log(t)$ là một hàm lồi (hoặc $\log(t)$ là hàm lõm), áp dụng bất đẳng thức Jensen: $\mathbb{E}[\log(t)] \leq \log(\mathbb{E}[t])$, ta có thể đưa toán tử kỳ vọng vào bên trong dấu tổng:

$$\mathbb{E} \left[\log \sum_{j=1}^N \frac{p(y_j | x)}{p(y_j)} \right] \leq \log \mathbb{E} \left[\sum_{j=1}^N \frac{p(y_j | x)}{p(y_j)} \right] \quad (39)$$

Tách dấu tổng bên trong kỳ vọng thành 2 phần: vị trí $j = i$ (mẫu thật) và $N - 1$ vị trí $j \neq i$ (mẫu nhiễu):

$$\mathbb{E} \left[\sum_{j=1}^N \frac{p(y_j | x)}{p(y_j)} \right] = \mathbb{E}_{y_i \sim p(y|x)} \left[\frac{p(y_i | x)}{p(y_i)} \right] + \sum_{j \neq i} \mathbb{E}_{y_j \sim p(y)} \left[\frac{p(y_j | x)}{p(y_j)} \right] \quad (40)$$

Tính tích phân (hoặc tổng xác suất) cho từng phần:

- Với mẫu thật ($j = i$): $\mathbb{E}_{y_i \sim p(y|x)} \left[\frac{p(y_i | x)}{p(y_i)} \right] = \int p(y | x) \frac{p(y | x)}{p(y)} dy$ (Đại lượng này luôn ≥ 1).
- Với mẫu nhiễu ($j \neq i$): Vì mẫu nhiễu được rút từ phân phối biên $p(y)$, ta có:

$$\mathbb{E}_{y_j \sim p(y)} \left[\frac{p(y_j | x)}{p(y_j)} \right] = \int p(y) \frac{p(y | x)}{p(y)} dy = \int p(y | x) dy = 1 \quad (41)$$

- Vì có $N - 1$ mẫu nhiễu, tổng của chúng bằng: $(N - 1) \times 1 = N - 1$.

Thế ngược lại vào bất đẳng thức Jensen của Thành phần B:

$$B \leq \log(\mathbb{E}[\text{mẫu thật}] + N - 1) \approx \log(1 + N - 1) = \log N \quad (42)$$

Bước 4: Kết hợp lại. Thay Thành phần A và Thành phần B vừa tính được vào phương trình gốc khi ta tách 2 thành phần:

$$\mathbb{E}[\log p_{\theta}^*(i | \dots)] \geq I(X; Y) - \log N \quad (43)$$

Sắp xếp lại:

$$I(X; Y) \leq \mathbb{E}[\log p_{\theta}^*(i | \dots)] + \log N \quad (44)$$

Mà theo định nghĩa, hàm mất mát Cross-Entropy xếp hạng ($\mathcal{L}_{\text{Global}}(\theta)$) chính là giá trị trừ kỳ vọng của log xác suất dự đoán đúng: $\mathcal{L}_{\text{Global}}(\theta) = -\mathbb{E}[\log p_{\theta}^*(i | \dots)]$.

Do đó, ta có hệ thức cuối cùng hoàn chỉnh:

$$I(X; Y) \geq \log N - \mathcal{L}_{\text{Global}}(\theta) \quad (45)$$

Ý nghĩa: Ranh giới trên của lượng thông tin mô hình có thể học được bị giới hạn nghiêm ngặt bởi $\log N$. Muốn mô hình thông minh hơn và hiểu sâu hơn, bắt buộc phải tăng quy mô tập mẫu nhiễu N .